# KUBIG

**CNN** and MLP

실전 2반 조민제, 김도윤, 이지현, 이노아, 오석준 목차

1 데이터

2 전처리

3 모델링


4 결<del>론</del>

# Part 1

데이터

# 1. 데이터


#### EDA - 데이터 <del>불균</del>형



55934개의 negative 1066개의 positive

# 1. 데이터

#### ■ EDA - 데이터 결측치



171개 feature 中 결측치 비율 20%이상 24개

# Part 2

전처리

## 결측치 처리

Iterative Imputer

KNN Imputer

## Oversampling

- Adasyn
- SMOTE
- K-means SMOTE
- Borderline SMOTE

#### 결측치 처리 - Iterative Imputer (multivariate Imputer)





Figure 1: Main steps used in multiple imputation.

#### 결측치 처리 - KNN Imputer




hyperparameterimputer = KNNImputer(n\_neighbors=5, weights="distance")

N = 5, 6, 7

Weights

=
uniform, distance

#### Oversampling - SMOTE (k-nn기반)




● Minority class에서 가장 가까운 이웃들을 찾음 - 군집 형성

그후, 이웃들 사이에 선을 그어 그 선들에 무작위의 점을 생성

- Majority class samples
- Minority class samples
- Synthetic samples

#### Logistic Regression - SMOTE (k-nn기반)




None

Test cost is: 258780

\*\*\*\*\*\*\*\*\*\*\*\*


## Oversampling - Adasyn



● SMOTE + 랜덤생성

● SMOTE를 할 때보다 큰 분산을 가져서 좀 더 현실적

#### Logistic Regression - Adasyn




None

Test cost is: 347540


\*\*\*\*\*\*\*\*\*\*\*\*\*

#### Oversampling - K-means SMOTE




● 가까운 군집 별로 데이터를 생성하여, 기존 SMOTE가 noise를 많이 생성하는 단점을 보완

#### Logistic Regression - K-means SMOTE



None Test cost is: 32290


#### Oversampling - Borderline SMOTE



● 다른 class와의 경계(borderline) 에 있는 샘플들을 늘림으로써 분류하기 어려운 부분에 집중

**Fig. 1.** (a) The original distribution of Circle data set. (b) The borderline minority examples (*solid squares*). (c) The borderline synthetic minority examples (*hollow squares*).

#### Logistic Regression - Borderline SMOTE



None

Test cost is: 166690

#### 나머지

● 데이터 분리

데이터 셋을 train 데이터와 validation 데이터로 나눠줍니다.

총 57000개의 데이터를 45600개의 train 데이터와 11400개의 validation 데이터로 나눠줍니다. • Feature 제거

총 171개의 feature 중에서 결측치 비율이 20%가 넘는 24개의 feature를 제거합니다.

총 147개의 feture가 남습니다.

## 8개의 전처리 데이터 선정

| 데이터이름  | Imputer                    | Oversampling     |
|--------|----------------------------|------------------|
| NA1    | Iterative imputer          | Adasyn           |
| NA2    | Iterative imputer          | borderline smote |
| NA3    | Iterative imputer          | borderline smote |
| MJ1    | knn imputer (uniform, k=5) | X                |
| MJ2    | knn imputer (uniform, k=5) | K-means smote    |
| K5dist | knn imputer(distance,k=5)  | X                |
| K6dist | knn imputer(distance,k=6)  | X                |
| K7dist | knn imputer(distance,k=7)  | X                |

SelectKbest (k = 144)

# Part 3

모델링

- MLP
- CNN
- FCN

Model

- Sigmoid
- Softmax
- ReLU

Activation


#### Loss

- CrossEntropy
- BinaryCrossEntropy

## Optimizer

- SGD + Momentum
- Adam
- RMSprop

### MLP (Multi-Layer Perceptron)



#### MLP - hyperparameter tuning


- Activation
- Batch\_size
- Layer 수
- Dropout1
- Dropout2
- Epoch
- Initializer
- Optimizer
- Units1
- Units2




- Activation: relu
- Batch\_size: 128
- Layer 수: 2
- Dropout1:0.0
- Dropout2:0.2
- Epoch: 10
- Initializer: lecun\_uniform
- Optimizer: adam
- Units1:256
- Units2:32

## MLP - 결과

#### Oversampling O




#### MLP - 결과(K5dist)




• Total cost: 20140


Average cost: 1.77

#### **CNN** (Convolutional Neural Network)






#### **CNN** (Convolutional Neural Network)




# CNN 모델 학습 결과

| 모 델 명   | Train<br>Total Cost | Validation<br>Total Cost |
|---|---------------------|--------------------------|
| CNN (loss:CrossEntropy activation:Softmax optimizer:SGD+Momentum)       | 61.6115             | 264.1665                 |
| CNN (loss:BinaryCrossEntropy activation:Sigmoid optimizer:SGD+Momentum) | 9.2105              | 38.6400                  |
| CNN<br>(loss:CrossEntropy activation:Softmax optimizer: Adam)           | 9.1885              | 36.4035                  |
| CNN (loss:BinaryCrossEntropy activation:Sigmoid optimizer:Adam)         | 9.1885              | 39.3855                  |

#### FCN



#### FCN



## FCN 모델 학습 결과

| 모델명   | Train<br>Total Cost | Validation<br>Total Cost |
|---|---------------------|--------------------------|
| FCN (loss:CrossEntropy activation:Softmax optimizer:SGD+Momentum)       | 9.1995              | 38.7715                  |
| FCN (loss:BinaryCrossEntropy activation:Sigmoid optimizer:SGD+Momentum) | 9.2105              | 38.9035                  |
| FCN<br>(loss:CrossEntropy activation:Softmax optimizer: Adam)           | 9.1995              | 37.5875                  |
| FCN (loss:BinaryCrossEntropy activation:Sigmoid optimizer:Adam)         | 9.1995              | 38.8595                  |

# Part 4

결론

#### 해석

## 하이퍼파라미터 튜닝 결론

- Activation function은 relu / Optimizer는 adam이 가장 성능이 좋음
- Dropout은 대체로 없는 것이 좋음
- 층 개수와 성능이 비례하지 않음. 성능이 좋은 모델들은 층을 2개만 쌓아도 잘 나옴.
- Batch size는 작을 때보다 클 때 (128) 성능이 좋음
- 가중치 초기화는 대체로 uniform이 normal보다 성능이 좋음


#### 해석

# Imputation < Imputation + Oversampling

- MLP에서는 오버 샘플링까지 한 데이터가 성능이 좋았음.
- 오버샘플링을 하지 않은 경우에는, 학습할 때 성능이 들쭉날쭉하고 데이터마다 결과가 상이
- 성능, 안정성 모든 면에서 좋은 오버샘플링 방식을 선택하는 것이 적합


#### 해석

# NA1 - (Oversampling O) 학습 그래프



#### 해석

# K5dist - (Oversampling X) 학습 그래프



#### 해석

• 실제로, 오버샘플링 데이터에서 성능이 좋았던 모델(NA1 – RE)과 오버샘플링 없이 Imputation만 진행한 데이터에서 성능이 좋았던 모델 (k5dist)의 학습 그래프를 비교해보면 오버샘플링 데이터가 안정적

#### 해석

# 오버샘플링 데이터셋의 성능이 좋은 이유는?

- 비대칭 데이터 셋에서는 정확도가 높아도, recall이 급격히 작아지는 현상 발생
- 하지만, 우리 데이터는 FN에 대한 가중치가 크고, 따라서 recall (실제 positive class를 맞게 예측한 비율)이 중요
  - neg를 pos로 분류하는건 10달러의 비용
  - pos를 neg로 분류하는건 500 달러의 비용

Cost = (10 \* FP) + (500 \* FN)

$$(Recall) = \frac{TP}{TP + FN}$$

• 또한, 신경망 모델의 특성상 데이터가 많이 확보될수록 유리

#### Test data

Confusion Matrix

| 18586 | 105 |
|-------|-----|
| 69    | 240 |

Accuracy: 0.9908421052631579

Confusion Matrix: 35550

# 감사합니다